

Развертывание ML моделей

Силлабус

Семестр	2
Зачетные единицы	5 ЗЕ
Длительность	16 марта — 24 мая (9 недель)
Аттестация	Дифференцированный зачет

[Аннотация](#)

[Цель дисциплины](#)

[Преподаватели](#)

[Результаты обучения](#)

[Логика прохождения](#)

[Тематический план](#)

[Практика](#)

[Аттестация](#)

Аннотация

Дисциплина направлена на формирование понимания принципов проектирования, развертывания и сопровождения машинного обучения в промышленной среде. В рамках дисциплины рассматриваются архитектурные подходы к построению ML-систем, проектирование API, микросервисная архитектура, инфраструктура как код, контейнеризация, CI/CD, MLOps, мониторинг и наблюдаемость моделей и данных.

Дисциплина ориентирована на подготовку специалистов, способных разрабатывать, внедрять и поддерживать ML-сервисы в условиях реальной нагрузки, требований к качеству, воспроизводимости и масштабируемости.

Цель дисциплины

Формирование компетенций в области проектирования, развертывания и эксплуатации ML-систем в продакшене, включая архитектуру сервисов, автоматизацию инфраструктуры, CI/CD, мониторинг моделей и данных, проектирование полного жизненного цикла машинного обучения.


Преподаватели



Сергей Доронин

Автор дисциплины, ведет семинары

- ООО «Астраханские цифровые технологии» (телеком), ведущий инженер-программист (2022 — н. вр.).
- ООО «МГ Экспорт-Импорт» (финтех), программист (2019–2021).
- ООО «РанФин» (финтех), программист (2017–2019).



Даниил Пилипенко

Автор дисциплины, читает лекции

- Выпускник МГУ им. М. В. Ломоносова, кандидат наук.
- Разработчик с 2004 г. (основные технологии — Java, PHP и frontend), руководитель разработки (тимлид, СТО) с 2008 г.
- Технический директор компании SW Development.
- Директор центра подбора и оценки IT-специалистов SymbioWay.



Доронькин Максим

Автор дисциплины

- Senior Machine Learning Engineer с опытом работы в России, Германии и Нидерландах.
- Ведущий эксперт по ИИ Центра компетенций по большим данным МГУ, Индустриальной лаборатории ИИ Сеченовского университета, стартап-акселератора «Ингрия» Санкт-Петербурга.
- СТО и Head of AI в компании SkyTrainer.
- Преподаватель в НИУ ВШЭ и МФТИ.
- Автор ряда статей по тематике применения ML в различных областях и построения продуктовых решений, победитель соревнований по ML.

Пререквизиты и постреквизиты

Какие дисциплины помогут в освоении:

- Программирование на Python.
- Основы машинного обучения.
- Глубокое обучение в науках о данных.

В каких дисциплинах понадобится далее:

- Проектный практикум.
- НИР.
- ВКР.

Результаты обучения

После прохождения дисциплины вы будете:

- Понимать принципы проектирования и документирования API, их роли в архитектуре сервисов и ML-систем.
- Понимать современные подходы к архитектуре приложений и роли микросервисов в ML и продакшене.
- Применять принципов инфраструктуры как кода и основных инструментов управления конфигурациями.
- Настраивать контейнеры и оркестрации в ML-продуктах.
- Понимание полного пути модели от разработки до поддержки и улучшения.
- Выстраивать архитектурные решения, необходимые для сервисов инференса.
- Понимать роли автоматизации в жизненном цикле ML.
- Настраивать мониторинга модели и данных в продакшене.
- Проектировать комплексные ML-системы и конвейеров.

Логика прохождения

Программа дисциплины состоит из нескольких модулей. Каждый модуль включает в себя:

- Материал на учебной платформе для самостоятельного изучения в удобное вам время, но в рамках длительности дисциплины.
- Синхронные занятия с преподавателем, даты и время которых указываются в общем расписании вашего потока.

Материал на платформе:

- Видеолекции.
- Конспекты.
- Домашние задания.

Как проходит обучение на дисциплине:

- Самостоятельно изучаете материал асинхронных занятий. Эти знания пригодятся для работы на синхронных занятиях.
- Посещаете общие практикумы и работаете с преподавателем. Если хотите углубиться в тему, приходите на продвинутый семинар.
- Выполняете домашнее задание по теме модуля. Если возникают вопросы по выполнению задания, вы можете разобрать их на консультации.

Синхронные занятия проходят в следующих форматах:

- **Практикум.** Краткое повторение теории, решение практических задач от преподавателя, разбор решений, групповые работы. В одну неделю проходит два общих практикума и один дополнительный практикум продвинутого уровня. Весь материал преподаватель передает на занятии или перед ним. Записи вебинаров выкладываются в доступ в течение нескольких дней.
- **Консультации по решению домашних заданий.** Возможность задать вопрос по теоретическому материалу, решение «подводящих» к домашнему заданию задач, разбор от преподавателя. Весь материал преподаватель передает на занятии. Консультации — дополнительная часть программы, организуются по массовому запросу.

Тематический план

Модуль 1. Проектирование API

Темы:

1. Архитектура верхнего уровня. Адресация ресурсов.
2. Протокол HTTP.
3. Методы HTTP-запросов.
4. Коды HTTP-ответов.
5. HTTP-заголовки. Куки и сессии.
6. Формат JSON.

7. Стандарт REST.
8. Инструменты проектирования API.

Домашнее задание: знакомство с API, создание сервера, описание эндпоинтов.

Синхронные занятия:

- Эволюция архитектуры до RestAPI и GRPC, WDSL. HTTP. FastAPI. Библиотека Requests.
- Форматы передаваемых данных XML, JSON. Форматы описания Swagger/OpenAPI.
- Lambda- и Карпа-архитектура на основе Kafka.

После прохождения модуля вы сможете:

- Объяснять устройство REST API и принципы адресации ресурсов.
- Выбирать корректные HTTP-методы для задач.
- Оценивать корректность и полноту HTTP-ответов и кодов.
- Проектировать структуру JSON-объектов для передачи данных.
- Строить спецификацию API для микросервиса и ML-сервиса.

Модуль 2. Микросервисная архитектура

Темы:

1. Монолитные приложения.
2. Сервис-ориентированная архитектура (SOA).
3. Микросервисная архитектура (MSA).
4. Принцип разделения монолитов на микросервисы.
5. Взаимодействие с MSA. API Gateway.

Синхронные занятия:

- Majestic Monolith / Microservices Serverless, принципы разделения монолита.
- Библиотека Diagrams, обоснование паттернов интеграции.
- Продуктовый манифест и ML-манифест.

Домашнее задание: переход от монолита к микросервисам, документирование; разработка дизайна ML-системы табличных данных.

После прохождения модуля вы сможете:

- Сравнивать монолит, SOA и микросервисы.
- Обосновывать разбиение монолита на сервисы.
- Проектировать схему взаимодействия сервисов.
- Определять роль API Gateway и паттернов интеграции сервисов.
- Проектировать ML-системы для табличных данных.

Модуль 3. Инфраструктура как код, Ansible и Terraform

Темы:

1. Основы Infrastructure as Code (IaC).
2. Ansible: плейбуки, инвентари, роли.
3. Modern Data Stack.
4. Terraform.

Синхронные занятия:

- Развертывание инфраструктуры Ansible/Terraform.
- Modern Data Stack, AutoMLOps: Nuclio.
- Детектирование аудиофрагментов, проектирование ML-системы работы с аудиоданными.

Домашнее задание: развертывание инфраструктуры с помощью Ansible, Terraform; разработка дизайна ML-системы аудиоданных.

После прохождения модуля вы сможете:

- Автоматизировать конфигурацию серверов.
- Описывать инфраструктуру декларативно.
- Настраивать окружение для ML/DS-стека.
- Создавать воспроизводимые окружения.
- Проектировать ML-системы для аудиоданных.

Модуль 4. Контейнеризация с Docker и Kubernetes

Темы:

1. Введение в Docker. Контейнеры и контейнеризация.
2. Оптимизация docker-образов для ML (меньший размер, кеширование).
3. Многостадийные сборки.
4. Кеширование pip-зависимостей.
5. Кубернетис и виртуализация.

Синхронные занятия:

- Docker.
- Многостадийные сборки, Kubernetes.
- ML-pipeline.

Домашнее задание. Написать Dockerfile для ML-приложения, настроить внешние и внутренние сети, тома хранения и рестарт, минимальные и максимальные границы памяти и ЦПУ в docker-файле. Провести базовый деплой сервиса в Kubernetes, используя YAML-файлы.

После прохождения модуля вы сможете:

- Создавать и оптимизировать docker-образы.
- Писать Dockerfile для ML-приложений.
- Настраивать сети, volumes, многостадийные сборки.
- Проводить базовый деплой сервиса в Kubernetes.

Модуль 5. Основы воспроизводимого машинного обучения. Жизненный цикл MLOps

Темы:

1. Введение в полный цикл MLOps.
2. Почему Jupyter-ноутбуки недостаточны для продакшена.
3. Четыре столпа продакшена.
4. Специализированные хранилища признаков.

Синхронные занятия:

- Цикл MLOps, paperworks.
- Feast, HortonWorks.
- Проектирование ML-системы для размытия лиц на изображениях.

Домашнее задание. Ограничения ноутбуков Collab при разработке ML-систем по сравнению с Marimo, проектирование схемы хранилища признаков, разработка схемы ML-системы для размытия лиц на изображениях.

После прохождения модуля вы сможете:

- Пояснять роль MLOps и ограничения ноутбуков.
- Применять подходы reproducibility.
- Проектировать хранилища признаков.
- Обосновывать переход от экспериментов к продакшену.
- Проектировать ML-систему заблюрования лиц.

Модуль 6. Архитектурные паттерны для обслуживания ML-моделей

Темы:

1. Монолит против микросервисов.
2. REST API как общий язык микросервисов.
3. Синхронная и асинхронная обработка.
4. Паттерны загрузки моделей.
5. Введение в контейнеризацию.

Синхронные занятия:

- Podman и аналоги.
- Синхронная и асинхронная обработка. Паттерны загрузки моделей.
- Дополнительный практикум: Lambda- и Карра-архитектура на основе Kafka.

Домашнее задание. Брокер очередей, спроектировать асинхронный API для модели. Стратегия загрузки моделей. Онлайн-загрузка данных в модель.

После прохождения модуля вы сможете:

- Сравнивать архитектуры инференса (монолит vs MCA).
- Проектировать асинхронный API для модели.
- Оценивать необходимость асинхронной обработки.
- Выбирать стратегии загрузки моделей.

Модуль 7. Автоматизированное развертывание с помощью CI/CD

Темы:

1. Что такое CI/CD.
2. Концепция непрерывного обучения для ML.
3. Роль конвейера CI/CD в MLOps.
4. Введение в GitHub Actions.
5. Стратегии развертывания: blue-green, canary.
6. A/B-тестирование для ML-моделей.

Синхронные занятия:

- Что такое CI/CD. GitLab CI/CD, GitLab Runner.
- Стратегии развертывания: blue-green, canary. A/B-тестирование для ML-моделей.
- Введение в GitHub Actions.

Домашнее задание. Настроить CI/CD-пайплайн для ML-сервиса с использованием GitLab. Стратегия деплоя. A/B-тестирование для ML-модели и архитектуры по Metrics Driven Development.

После прохождения модуля вы сможете:

- Настраивать CI/CD для ML-сервисов.
- Оценивать стратегии выкатывания и их влияние на риски.
- Планировать A/B-тестирование для ML-модели.
- Проводить A/B-тестирование архитектуры в Metrics Driven Development.

- Создавать GitHub Actions workflows.

Модуль 8. Мониторинг и наблюдаемость в продакшене

Темы:

1. Два аспекта мониторинга ML: мониторинг ПО/инфраструктуры; мониторинг модели/данных.
2. Определение ключевых метрик: бизнес и технических.
3. Определение дрейфа данных, дрейфа концепции и деградации модели.
4. Data Observability, Data Quality OPS.

Синхронные занятия:

- Мониторинг ПО и инфраструктуры; мониторинг модели и данных. Prometheus, Grafana.
- Определение дрейфа данных, дрейфа концепции и деградации модели. Data Observability, Data Quality OPS. EvidentlyAI, DeepChecks, DQOPS.
- Проектирование ML-системы для Virtual Product Placement.

Домашнее задание. Ключевые бизнес- и технические метрики для ML-системы, настройка мониторинга состояния приложения и ML-модели с использованием Prometheus, Grafana, MLflow. Разработка схемы ML-системы для Virtual Product Placemen.

После прохождения модуля вы сможете:

- Определять ключевые бизнес- и технические метрики.
- Настраивать мониторинг состояния приложения и модели.
- Обнаруживать деградацию модели и дрейф данных.
- Применять подходы Data Quality Ops.
- Проектировать ML-системы для Virtual Product Placement.

Модуль 9. CI/CD, продвинутая оркестрация, инфраструктура как код и ML-system Design

Темы:

1. Различие между оркестрацией и CI/CD.
2. Проектирование полного цикла автоматизированного конвейера

переобучения.

3. Принципы инфраструктуры как кода (IaC): декларативная, повторяемая и версионизируемая инфраструктура.

Синхронные занятия:

- Проектирование полного цикла автоматизированного конвейера переобучения. Airflow, Dagster, Prefect.
- Принципы инфраструктуры как кода (IaC): декларативная, повторяемая и версионизируемая инфраструктура. AutoMLOPS: Nuclio.
- Проектирование и создание пайплайна модели, которая обслуживает весь жизненный цикл от очистки данных до вывода модели.

Домашнее задание. Разработка дизайна ML-системы для расчета складских запасов сетевого магазина, применение принципов IaC для реализации инфраструктуры ML-системы. Управление рисками (детекция дрейфа, деградации модели).

После прохождения модуля вы сможете:

- Проектировать автоматизированный ML-конвейер переобучения.
- Обосновывать архитектурные решения в ML System Design.
- Применять принципы IaC для большого ML-продукта.
- Разрабатывать дизайн ML-систем с учетом нагрузки, качества и рисков.
- Проектировать ML-систему для расчета складских запасов сетевого магазина.

Практика

Форматы практических заданий на дисциплине:

- Задания для самопроверки.
- Домашнее задание 1. Знакомство с API.
- Домашнее задание 2. Переход от монолита к микросервисам.
- Домашнее задание 3. Создаем облачную инфраструктуру.
- Домашнее задание 4. Пишем Dockerfile по правилам.
- Домашнее задание 5. Обеспечиваем воспроизводимость эксперимента.

- Домашнее задание 6. Подключаем очереди и асинхронную обработку.
- Домашнее задание 7. Собираем конвейер CI/CD.
- Домашнее задание 8. Мониторим все.
- Домашнее задание 9. Проектируем систему целиком.

Внимание! Сдавайте оцениваемые задания заранее, а не в последние минуты перед дедлайном. Иначе работа может не успеть загрузиться, и значит, мы не примем ее к оцениванию.

Аттестация

Общая информация:

- Дисциплина заканчивается дифференцированным зачетом.
- Итоговая оценка складывается из накопленной (70%) и оценки за экзамен (30%).
- Для получения автомата по дисциплине вам нужно получить не менее 30% от итоговой оценки (3 баллов).

Формулы оценивания. Накопленная оценка:

ДЗ 1	ДЗ 2	ДЗ 2	ДЗ 4	ДЗ 5	ДЗ 6	ДЗ 7	ДЗ 8	ДЗ 9
11,1%	11,1%	11,1%	11,1%	11,1%	11,1%	11,1%	11,1%	11,2%

Итоговый балл:

Накопленный балл * 0.7 + балл за диф. зачет * 0.3

Итоговое задание по дисциплине сдается в зачетную неделю. Это письменная работа с устной защитой — проектное задание на основе домашних заданий дисциплины: разработка ML-системы. На выполнение отводится 3 дня.

Балльная система:

Проценты	Баллы	Оценка
95–100	10	Отлично
85–94	9	
75–84	8	
65–74	7	Хорошо
55–64	6	
45–54	5	
35–44	4	Удовлетворительно
25–34	3	
15–24	2	Неудовлетворительно
0–14	1	