

Зачеты и экзамены (501)

[Главная страница](#) / [Мои курсы](#) / [Зачеты и экзамены](#) / [Летняя сессия 26](#) / [06.06 Развертывание ML-моделей: диф. зачет \(письменная работа\)](#).

06.06 Развертывание ML-моделей: диф. зачет (письменная работа)

Вы выполняете задание как завершающий проект дисциплины «Развертывание ML-моделей». Формат выполнения — индивидуальная работа.

Письменная работа. В рамках проекта необходимо создать пайплайн модели, которая обслуживает весь жизненный цикл: от очистки данных, подачи их в необученную модель, обучения модели и до вывода модели, не соответствующей метрикам качества, из эксплуатации через переключение трафика на новую обученную модель.

Базовый балл формируется по результатам проверки письменной работы. За письменную часть можно получить до 10 баллов.

Устная защита. После 01.06.2026 состоятся устные защиты работ. Распределение по дням защиты будет опубликовано отдельным постом от координатора.

На защите необходимо будет рассказать о ходе проектирования, продемонстрировать ключевые этапы работы и показать, что спроектированная система соответствует заявленным характеристикам, а также ответить на дополнительные вопросы преподавателя. Перед защитой рекомендуется повторить материалы дисциплины.

Для чего нужна устная защита:

- для подтверждения самостоятельного выполнения работы;
- проверки понимания принятых решений и сделанных выводов;
- уточнения спорных или пограничных моментов.

Отдельная оценка за устную часть не выставляется. По итогам устной защиты преподаватель вправе скорректировать балл за письменную работу как в сторону повышения, так и в сторону понижения.

Повышение итогового балла возможно в ситуациях, когда устная защита демонстрирует более высокий уровень владения материалом, чем отражено в письменной работе. Например:

- глубокое понимание используемых методов и решений;
- обоснованные интерпретации результатов;
- уверенные и корректные ответы на вопросы преподавателя;
- осознанные решения при выборе методов, моделей и параметров.

Понижение балла применяется, если устная защита выявляет несоответствие между письменной работой и уровнем понимания студента. Это может проявляться в следующих ситуациях:

- студент не понимает собственный код и не может объяснить написанные функции, операции или визуализации;
- выводы формальны или содержат ошибки и не соответствуют данным;
- присутствуют концептуальные ошибки и непонимание базовых понятий;
- студент не отвечает на вопросы или отвечает некорректно;
- наблюдаются признаки несамостоятельного выполнения работы, когда ответы указывают на заимствование решений без понимания.

Важно. При неявке на защиту студенту выставляется ноль баллов за экзамен, итоговая оценка формируется по накопленному баллу.

Тема задания

Проектируем ML-систему целиком.

Цели задания

Продемонстрировать владение базовыми принципами проектирования автоматизированного конвейера переобучения модели с использованием оркестрации и инфраструктуры как кода.

В ходе выполнения задания:

- вы спроектируете ML-систему целиком;
- создадите пайплайн модели, которая обслуживает весь жизненный цикл: от очистки данных, подачи их в необученную модель, обучения модели и до вывода модели, не соответствующей метрикам качества, из эксплуатации через переключение трафика на новую обученную модель.

Как выполнять задание

Шаг 1. Постановка цели. Выберите самую простую и понимаемую бизнес-задачу (например, для расчета складских запасов магазина достаточно трех таблиц — товар, склад, заказ). Выберите одну бизнес-метрику. Перепишите бизнес-требования на язык ML-проектирования.

Шаг 2. Выбор уровня сложности реализуемой системы. Составьте одностраничный манифест разработки ML-системы. Это ваш план, в котором вы заявляете уровень зрелости будущей ML-системы (0,1 или 2).


Разделы ML-манифеста:

1. Предыстория	Опишите цели и проблемы заказчика
2. Ценностное предложение	Опишите ценность, которую создает продукт или какие трудности он облегчает
3. Цели	Разбейте продукт на ключевые задачи, которые необходимо решить

4. Решение	Опишите решение, включая фиичи, интеграции, ограничения и то, что не будет входить в продукт. Какой уровень зрелости ML-системы вы заявляете? (0, 1 или 2)
5. Осуществимость	Опишите осуществимость решения и наличие у вас в текущий момент необходимых ресурсов
6. Данные	Определите источники обучающего набора данных и реального (прод) набора данных, а также процесс разметки данных на классы
7. Метрики	Дайте приоритет бизнес-показателям, которые отражают достижение целей из п.3
8. Оценка качества модели	Опишите офлайн- и онлайн-метрики
9. Подбор модели	Используйте итеративный подход к подбору модели для своей задачи
10. Инференс	Решите, будет ли систем ваыполнять обработку данных батчами или в реальном времени
11. Обратная связь	Каковы источники обратной связи от вашей системы, которые будете использовать для перехода к следующей итерации? Будете ли вы использовать MDD для принятия решений? (Да/Нет)
12. Управление проектом	Определите количество необходимых разработчиков, конечные результаты и прогнозируемые сроки


Уровни ML-системы

Уровень 0:




- Нет версионирования кода.
- Нет загрузки онлайн-данных.

Уровень 1:




- Есть версионирование кода.
- Есть CI/CD-пайплайн выкатки модели на прод.
- Есть фича-стор (хранилище признаков).
- Есть сервинг модели через API.
- Есть мониторинг качества предсказания модели.

Уровень 2:



- Есть версионирование кода.
- Есть CI/CD пайплайн выкатки модели на прод.
- Есть фича-стор (хранилище признаков).
- Есть сервинг модели через API.
- Есть мониторинг качества предсказания модели.
- Есть система управления экспериментами (DVC/MLflow/...).
- Есть оркестратор (Airflow/Dagster/...).

Шаг 3. Создание ML-системы. Создайте с помощью любого декларативного инструмента инфраструктуру с таким количеством компонентов, которое требуется для выбранной архитектуры ML-системы. Не нужно гнаться за модой — включать сразу все возможные [компоненты из перечня](#).



Шаг 4. Управление рисками. Ни одна система не имеет 100% надежности, но тем не менее для каждого компонента инфраструктуры напишите индикатор SLI и SLO, который показывает нормальную работу системы.

Шаг 5. Принятие решений по Metrics Driven Development. Вам предоставлены 2 набора данных по времени отклика (latency) и визуализация. Как вы будете в будущем улучшать систему? Продемонстрируйте навык обоснования архитектурного решения по MDD.

```
import matplotlib.pyplot as plt; import seaborn as sns; import numpy as np;
np.random.seed(42); plt.figure(figsize=(10, 6))
existing_system_responses = np.random.normal(loc=3.5, scale=0.4, size=500000)
improved_system_responses = np.random.normal(loc=2.0, scale=0.4, size=500000)
sns.kdeplot(existing_system_responses, label='Существующая система', fill=True, color='red')
sns.kdeplot(improved_system_responses, label='Улучшенная система', fill=True, color='green')
plt.title('Сравнение времени отклика системы'); plt.xlabel('Время отклика (секунды)')
plt.ylabel('Наблюдения'); plt.legend(); plt.grid(True, linestyle='--', alpha=0.7)
ax = plt.gca(); ymin, ymax = ax.get_ylim(); num_ticks = 5; new_yticks = np.linspace(ymin, ymax, num_ticks)
new_yticklabels = [f'{int((tick / ymax) * 100)}%' if ymax != 0 else '0%' for tick in new_yticks]
ax.set_yticks(new_yticks); ax.set_yticklabels(new_yticklabels); plt.show()
```



Формат сдачи

- Вы сдаете две ссылки:
- на код в репозитории GitHub/Gitlab. Репозиторий должен также включать все текстовые артефакты;
 - реальный, развернутый в облаке сервис. Сервис должен продолжать работать до устной защиты.

Критерии оценивания

Результаты проверки будут опубликованы после устной защиты.

Максимальный балл: 10.

Критерии	Баллы
1. Постановка цели	
Студент не понимает, как для задачи подбирается метрика	0
Выбрана верная бизнес-метрика, но неверно подобраны метрики ML-проектирования	1
Выбрана верная бизнес-метрика, подобраны верные метрики ML-проектирования	2
2. Уровень зрелости ML-системы	

Нет манифеста или не заявлен уровень зрелости или заявлен и соответствует уровню 0 по классификации	0
Есть архитектура DevOps, нет архитектуры MLOps Заявлен и соответствует уровню 1 по классификации	1
Есть задокументированное четкое понимание архитектуры пайплайна, который обслуживает весь жизненный цикл: от очистки данных, подачи их в необученную модель, обучения модели до вывода модели, не соответствующей метрикам качества, из эксплуатации через переключение трафика на новую обученную модель. Заявлен и соответствует уровню 2 по классификации	2
3. Создание ML-системы	
Есть код на GitHub/GitLab, IaC через CI/CD не используется	0
Есть код на GitHub/GitLab, но не предусмотрена деинсталляция инфраструктуры после завершения работы, не все компоненты ML-системы работают	1
Есть код на GitHub/GitLab, есть грамотная реализация IaC для инфраструктуры ML-системы, все заявленные в проекте компоненты ML-системы работают: - если это бэкенд-сервис, то приложен скриншот терминала после выполнения команды docker ps, чтобы было видно STATUS Up(healthy); - если это фронтенд-сервис, то эндпоинт /health должен быть доступен и отвечать кодом статуса 200. Есть ссылка на реальный, развернутый в облаке сервис, он работает до момента устной защиты	2
4. Управление рисками	
Не сформулированы ключевые SLI ML-системы	0
Частично описаны SLI и уровни SLO: есть метрики из одного или двух уровней: - Технический — CPU, память, ошибки, Latency. - Модельный — AUC, Drift, Precision/Recall. - Бизнес-метрики — конверсия, CTR, возвраты пользователей	1
Описаны SLI на 3 уровнях и описаны критические уровни SLO: есть метрики из всех трех уровней: - Технический — CPU, память, ошибки, Latency. - Модельный — AUC, Drift, Precision/Recall. - Бизнес-метрики — конверсия, CTR, возвраты пользователей	2
5. Принятие решений по Metrics Driven Development	
Не применен MDD. Решение принято без обращения к статистике по двум наборам данных метрик системы. Есть данные, но нет статистического теста (решение на глазок)	0
Применен MDD. Статистический анализ проведен, но архитектурное решение не зафиксировано: - есть два набора данных метрик системы; - есть визуализация и сравнение распределений; - сформулированы гипотезы H0 и H1; - выбран уровень значимости p-value; - проведен статистический тест; - вывод о принятии/отклонении H0 сделан, но не оформлен в структурированный документ	1
Применен MDD. Статистический анализ проведен и оформлен в ADR: - все из уровня 1; - есть документ в формате ADR; - в разделе Decision зафиксированы H0 и H1, выбранный тест, p-value и итоговое архитектурное решение	2
Блокирующий критерий: устная защита. При неявке на устную защиту за работу выставляется 0 баллов. На устной защите необходимо показать, что спроектированная система соответствует заявленному в манифесте уровню	

Дополнительные условия оценки. Работа студента может быть аннулирована, если:

- в работе обнаружен плагиат;
- при выполнении задания использовались LLM.

Состояние ответа

Состояние ответа на задание	Ни одной попытки
Состояние оценивания	Не оценено
Последний срок сдачи	Воскресенье, 31 мая 2026, 23:59
Оставшееся время	Задание просрочено на: 10 час. 50 мин.
Критерии оценивания	Постановка цели Максимальный балл 2 Уровень зрелости ML-системы Максимальный балл 2 Создание ML-системы Максимальный балл 2 Управление рисками Максимальный балл 2 Принятие решений по Metrics Driven Development Максимальный балл 2
Последнее изменение	-

Комментарии к ответу

+

Комментарии (1)

Вольхин Сергей Александрович

- Пн, 1 июн 2026, 10:40

Здравствуйте! Не могу понять, почему не прикрепилась ссылка на мою работу. Прикрепляю в комментарии <https://github.com/SergeiVolkhin/uneemi-mlops>

Добавить комментарий...

[Сохранить комментарий](#)

[Отмена](#)

Помощь

[База знаний](#)

[Политики МФТИ](#)

Информация

[О системе](#)

[Студии самозаписи](#)

Документация

[По этой странице](#)

[Задать вопрос](#)

Поддержка

+7 (498) 713-92-15

learning@mipt.ru