

Развертывание ML моделей (501)

Домашнее задание 6. Подключение очереди и асинхронной обработки

Задание выполняется в рамках модуля 6 «Архитектурные паттерны для обслуживания ML-моделей». Формат выполнения — индивидуальная работа.

Работать можно в любой IDE (VS Code, PyCharm, Colab) или локальной среде с Docker и Python 3.

Форма сдачи — ссылка на GitHub-/GitLab-репозиторий или ссылка на Collab.

Цели задания

Задание направлено на понимание архитектурных решений, необходимых для сервисов инференса.

Как выполнять задание

[Скопируйте блокнот](#)

Шаг 1. Зачем нужна асинхронная обработка:


- Если используется простая модель (на деревьях DecisionTree /RandomForest) для коротких единичных данных, то асинхронная обработка **не нужна**: выигрыш будет минимальным, код усложнится.
- Если данные длинные и хорошо распараллеливаются, то **имеет смысл усложнить код**, чтобы код в памяти брал данные асинхронно и отдавал асинхронно — в этом случае процессоры будут максимально задействованы. Архитектура кода, когда данные поступают асинхронно и возвращаются асинхронно, называется событийно-ориентированная архитектура (Event-Driven Architecture, не путайте с Exploratory Data Analysis).

Шаг 2. Выбор брокера:

- Обоснуйте свой выбор брокера (Kafka/RabbitMQ/Redis*) для асинхронной обработки конвейера ML. **Redis хоть и не является брокером, но имеет встроенный паттерн PubSub, надежен и очень прост в изучении.*
- Создайте цепочку из 3 событий (можно использовать FastStreams).
- Опишите цепочку в формате AsyncApi.
- Если не удалось запустить AsyncApiStudio в коллабе, то можно запустить локально через git clone <https://github.com/asyncapi/studio.git> && docker build -f apps/studio/Dockerfile -t asyncapi/studio . && docker run asyncapi/studio.

Шаг 3. Зачем нужна стратегия (паттерн) загрузки моделей. Даже на самых быстрых NVMe-дисках загрузка модели Qwen3:14b весом 9ГБ сначала в RAM потом в VRAM занимает 15–20 секунд, а модели Qwen3:28b — примерно 40–60 секунд. Как объяснить пользователю, который отправил короткий запрос в модель, что нужно набраться терпения и что она работает, только сейчас не работает, а потом заработает? Есть, конечно, стратегия вообще не выгружать модели из памяти, но это крайность.

Опираясь на материалы семинара, выберите паттерн и загрузите модель (например, <https://huggingface.co/cointegrated/rubert-tiny2>).



Обоснуйте, почему выбран такой паттерн.

Шаг 4. Создать загрузку данных батчами в модель. Реализуйте паттерн батчинга (Batching) из раздаточных материалов модуля.

Шаг 5. Создать онлайн-загрузку данных в модель. В современных сервисах все работает на стримах: напишите код онлайн-загрузки данных в модель, опираясь на событийно-ориентированную архитектуру (Event-Driven Architecture) с помощью любого брокера (можно использовать библиотеку FastStreams).

Формат сдачи и отправка задания

Работа сдается в виде ссылки на GitHub-/GitLab-репозиторий (допускается ссылка на Collab).

Критерии оценки

Максимальный балл: 10.

Критерии	Баллы
Оценить необходимость асинхронной обработки	
Студент не понимает разницы между синхронной и асинхронной обработкой	0
Нелогичное обоснование использования асинхронной обработки	1
Есть логичное обоснование использования асинхронной обработки	2
Выбрать брокер очередей, спроектировать асинхронный API для модели	
Нет асинхронного API, неверно выбраны брокер	0
Есть асинхронный API для модели, неверно выбраны брокер	1
Есть асинхронный API для модели в формате AsyncAPI	2
Выбрать стратегию загрузки моделей и реализовать ее	

Паттерн не реализован или не запускается	0
стратегия(паттерн) загрузки моделей реализован(а) частично	1
Есть стратегия(паттерн) загрузки моделей	2
Создать загрузку данных батчами в модель	
Код отсутствует	0
Есть загрузка данных, но это не паттерн батчинга	1
Есть загрузка данных паттерном батчинга с таймаутом	2
Создать онлайн-загрузку данных в модель	
Онлайн-загрузка данных в модель отсутствует или не работает	0
Есть онлайн-загрузка данных в модель на связке Celery + RabbitMQ	1
Есть полноценная онлайн-загрузка данных в модель	2

Дополнительные условия оценки. Работа студента может быть аннулирована, если в работе обнаружен плагиат и/или при выполнении задания использовались LLM.

Помощь

[База знаний](#)

[Политики МФТИ](#)

Информация

[О системе](#)

[Студии самозаписи](#)

Документация

[По этой странице](#)

[Задать вопрос](#)

Поддержка

+7 (498) 713-92-15

learning@mipt.ru