

Развертывание ML моделей (501)

Домашнее задание 8. Мониторинг

Задание выполняется в рамках модуля 8 «Мониторинг и наблюдаемость в продакшене». Формат выполнения — индивидуальная работа. Работа выполняется локально или в docker-среде с использованием Prometheus и Grafana.

Форма сдачи — ссылка на GitHub-репозиторий со скриншотами работающего дашборда и алерта, конфигурацией (если применимо).

Цели задания

Освоить базовые приемы настройки мониторинга и алертинга для ML-сервиса:

- создать систему наблюдаемости с Prometheus и Grafana;
- определить SLO (Service Level Objective) для сервиса;
- настроить автоматический алерт при его нарушении.

Как выполнять задание

Скопируйте блокнот

На отдельной виртуальной машине установите и запустите через Docker следующие компоненты:

- Prometheus;
- Grafana;
- (опционально) ваш ML-сервис с /metrics на порту 8000.

Пример docker-compose.yml:

```
version: "3.9"
services:
  prometheus:
    image: prom/prometheus:latest
    volumes:
      - ./prometheus.yml:/etc/prometheus/prometheus.yml
    ports:
      - "9090:9090"

  grafana:
    image: grafana/grafana:latest
    ports:
      - "3000:3000"
    depends_on:
      - prometheus
```

Шаг 1. Определить ключевые бизнес- и технические метрики. Создайте дерево метрик, которое бы учитывало точки зрения разных команд. Примеры возможных SLO:

- Latency (p95) < 1 сек.;
- Error Rate < 1%;
- Availability > 99%.

Шаг 2. Настройка Prometheus. Выберите один показатель (например, Latency) и создайте соответствующую prometheus-метрику в коде сервиса:

```
from prometheus_client import Histogram
LATENCY = Histogram("request_latency_seconds", "Request latency")

def handle_request():
    start = time.time()
    # Выполнение запроса
    LATENCY.observe(time.time() - start)
```

Добавьте в prometheus.yml источник метрик:

```
scrape_configs:
  - job_name: "ml_service"
    static_configs:
      - targets: ["host.docker.internal:8000"]
```

Проверьте доступность /metrics по адресу http://localhost:9090/targets.

Выведите эту метрику на дашборд Grafana:

- Откройте Grafana (http://localhost:3000).
- Подключите источник данных Prometheus.
- Создайте новый Dashboard → Panel → Запрос:
histogram_quantile(0.95, sum(rate(request_latency_seconds_bucket[5m])) by (le))
- Настройте визуализацию графика p95 latency.

Настройте алерт в Grafana:

- В панели выберите Alert → Create alert rule. Укажите условие, например: p95_latency > 1.
- Настройте частоту проверки (evaluate every 1m).
- Добавьте канал уведомлений (Slack, email, Telegram).
- Проверьте, что при превышении порога алерт срабатывает.

Пример правила (YAML):

```
apiVersion: 1
groups:
- name: latency_alerts
  rules:
  - alert: HighLatency
    expr: histogram_quantile(0.95, sum(rate(request_latency_seconds_bucket[5m])) by (le)) > 1
    for: 2m
    labels:
      severity: warning
    annotations:
      summary: "High request latency detected"
      description: "p95 latency exceeded 1s for 2 minutes."
```

Искусственно увеличьте время отклика модели (например, time.sleep(2)) и убедитесь, что алерт перешел в состояние Alerting.

Сделайте скриншоты:

- панели с метрикой;
- окна алерта;
- уведомления в Slack, email или Telegram (если настраивали).

Шаг 3. Обнаружить деградацию модели и дрейф. Вспомните [материалы семинара](#) и измените подаваемые в модель данные, чтобы продемонстрировать либо дрейф данных, либо дрейф концепции, либо деградацию модели.

Подаваемый в модель пакет данных (Current batch) должен отличаться от эталонного пакета данных (Reference batch), иначе не будет видно смещение распределения (дрейф).

```
data_report.run(
    reference_data= X,          <-эталонные данные
    current_data=   X*1000      <-отличающиеся данные
)
```

Шаг 4. Запустите центр управления качеством данных:

- Выполните bash команды:

```
apt install python3-pip -y
pip install --user dqops
echo "Нажмите у в ответ на запрос Log in to DQOps Cloud? [Y,n]: y"
python -m dqops
```

- Создайте таблицу в базе данных (MySQL/PostgreSQL).
- Подключитесь к своей базе данных на вкладке Data Sources.
- Импортируйте таблицу из базы данных в DQOps.
- Измените структуру столбцов таблицы в базе данных.
- Перейдите на вкладку Incidents в DQOps.
- Подтвердите наличие инцидента с качеством данных и сделайте снимок экрана.

Шаг 5. Разработать схему ML-системы для цифровой рекламы, встраивающей бренды в видеопоток в реальном времени. Начиная с 2023 году Netflix вставляет бренды в уже снятые сцены в зависимости от страны зрителя, позволяя заменять бренды в фильмах постфактум (например, Pepsi в фильме может превратиться в Coca-Cola).

Вспомните [семинар про сравнение архитектур Lambda и Kappa](#). Нужно выбрать оптимальную архитектуру и составить схематическое описание ML-системы с помощью библиотеки [Diagrams](#). Прежде чем принимать решение об архитектуре обработки данных, следует задать себе несколько вопросов:

- Какова природа и объем данных? Понимание типа данных (структурированные, неструктурированные, полуструктурированные) и объема данных: мы имеем дело с неструктурированными видеопотоками, которые хорошо параллелизируются.
- Какова требуемая скорость обработки? Хотите использовать обработку в режиме реального времени, микробатчинг, или пакетную обработку?
- Каков допустимый уровень задержки? Важность получения результатов с низкой задержкой может определять выбор между потоковой и пакетной обработкой.
- Каковы требования к отказоустойчивости? Если система не может позволить себе потерять какие-либо данные из-за сбоя, то потребуется HA-архитектура, для отработки отказа и резервирования.
- Какой уровень масштабируемости вам нужен? Если объем данных со временем значительно увеличится, то нужна масштабируемая архитектура.

Формат сдачи

Работа сдается в виде ссылки на репозиторий, содержащий:

- prometheus.yml;
- (опционально) docker-compose.yml;
- экспортированный дашборд Grafana (.json);
- скриншоты панели и алерта;
- README.md с описанием SLO, шагов настройки и результата.

Критерии оценки

Максимальный балл: 10.

Критерии	Баллы
----------	-------

Определить ключевые бизнес- и технические метрики для ML-системы	
Метрики не определены	0
Определены некоторые метрики, метрики перепутаны (бизнес-метрики в инфраструктуре и т. п.)	1
Определены отдельно ветви дерева: бизнес-метрики, метрики приложения, ML-метрики, метрики инфраструктуры	2
Настроить мониторинг состояния инфраструктуры, приложения и ML-модели с использованием Prometheus, Grafana, MLflow	
Окружение не развернуто, Prometheus или Grafana не запускаются, метрики не собираются.	0
Окружение частично настроено: сервисы запускаются, но Prometheus некорректно собирает метрики или есть ошибки в конфигурации	1
Есть дашборд мониторинга состояния инфраструктуры и модели, Prometheus и Grafana полностью развернуты, Prometheus успешно собирает метрики с ML-сервиса, таргеты отображаются как UP	2
Обнаружить деградацию модели и дрейф данных	
Студент не может сформулировать пример деградация модели, дрейф данных не реализован	0
дрейф данных определен, но реализован частично или некорректно	1
Приведен пример деградации модели и дрейфа данных	2
Обеспечить качество данных с Data Quality Ops	
Инцидент Data Quality отсутствует или алерт не работает	0
Неверно настроено обнаружение инцидента Data Quality и сработал ложный алерт	1
Обнаружен инцидент Data Quality и сработал алерт	2
Разработать схему ML-системы для Virtual Product Placement (цифровая реклама с помощью генеративного ИИ встраивает бренды в видеопоток)	
Нет схемы ML-системы для Virtual Product Placement	0
Есть схема ML-системы, но она нечитаемая или в нестандартном формате, или не используются стримы	1
Есть схема ML-системы для Virtual Product Placement, использующая стримы	2

Дополнительные условия оценки. Работа студента может быть аннулирована, если в работе обнаружен плагиат и/или при выполнении задания использовались LLM.

Помощь

[База знаний](#)

[Политики МФТИ](#)

Информация

[О системе](#)

[Студии самозаписи](#)

Документация

[По этой странице](#)

[Задать вопрос](#)

Поддержка

+7 (498) 713-92-15

learning@mipt.ru